Rapport : Data Challenge

1 Contexte du projet

Le but de ce projet est d'appliquer des techniques d'apprentissage automatique pour améliorer la capacité des détecteurs portatifs à reconnaître différents types de gaz. À partir des mesures recueillies par plusieurs capteurs, le modèle vise à prédire 23 niveaux d'alarme associés à divers gaz toxiques. Dans ce contexte, il est plus critique de ne pas détecter un gaz présent que de déclencher une alarme par erreur. Pour refléter cette priorité, la métrique utilisée est le Weighted RMSE, qui pénalise davantage les erreurs commises lorsqu'un gaz toxique est effectivement présent.

2 Description des données

Chaque échantillon du jeu de données correspond à des mesures enregistrées par plusieurs capteurs intégrés dans un détecteur de gaz portatif. Les données d'entrée comprennent 14 variables : 8 mesures principales (M4–M7 et M12–M15), 4 capteurs complémentaires (S1–S3 et R) ainsi que l'humidité absolue, qui influence la réponse des capteurs. Les sorties sont constituées de 23 niveaux d'alarme (c1 à c23) qui indiquent la présence ou non de différents gaz toxiques. Les ensembles d'entraînement et de test partagent la même structure mais proviennent de conditions physiques différentes, notamment en termes d'humidité et de concentration, afin d'évaluer la capacité du modèle à s'adapter à de nouveaux environnements.

3 Prétraitement des données

Avant la modélisation, plusieurs étapes de prétraitement ont été réalisées afin de garantir la qualité et la cohérence des données. Une vérification préalable a confirmé l'intégrité du jeu de données.
Aucune valeur manquante n'a été détectée dans les ensembles d'entraînement et de test, ce qui a permis d'éviter toute étape d'imputation.
Les variables d'entrée ont ensuite été standardisées à l'aide de la méthode *StandardScaler*, afin de ramener toutes les caractéristiques sur une même échelle et d'améliorer la convergence du modèle XGBoost.
Enfin, une carte de chaleur des corrélations a été tracée sur les 23 variables cibles pour analyser les relations entre les différents niveaux d'alarme. Cette visualisation met en évidence certaines corrélations positives entre classes similaires, ce qui justifie l'application d'une réduction de dimension (PCA) dans la phase suivante.

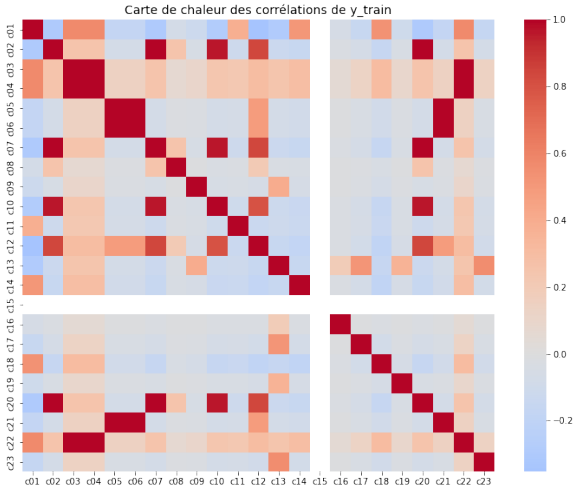


Figure 1: Carte de chaleur des corrélations entre les variables cibles

4 Réduction de dimension (PCA)

L'analyse des corrélations entre les variables cibles a révélé des dépendances importantes entre certaines classes, ce qui indique une redondance partielle de l'information. Pour réduire cette redondance et concentrer les informations les plus pertinentes, une Analyse en Composantes Principales (PCA) a été appliquée sur les 23 variables de sortie.
Le nombre de composantes principales a été choisi de manière automatique à partir d'un seuil de variance cumulée de 95 % . Ce choix assure un équilibre entre la réduction de la dimensionnalité et la préservation de l'information pertinente. Cela suggère que différents types de gaz toxiques partagent des modes de réponse communs sur les capteurs et que les composantes principales parviennent à capturer efficacement. Au terme de cette analyse, les 23 dimensions initiales ont été réduites à 6 composantes principales, ce qui permet de limiter le bruit, d'accélérer l'apprentissage du modèle et d'améliorer sa stabilité.
La courbe de variance expliquée cumulée montre qu'un petit nombre de composantes suffit à capturer l'essentiel de la variabilité des données. Ce constat confirme la pertinence de PCA avant la phase de modélisation.

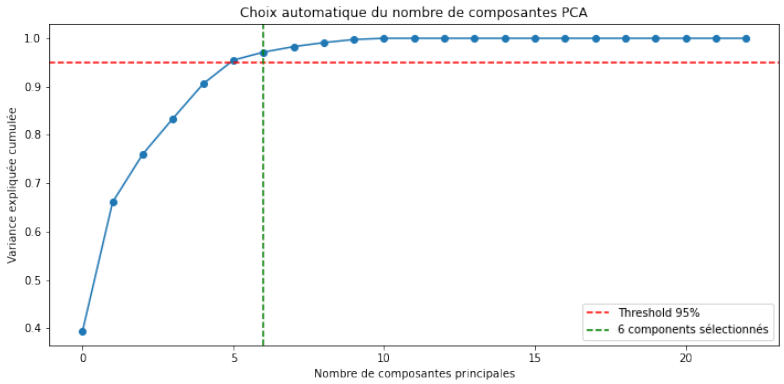


Figure 2: La courbe de variance expliquée cumulée

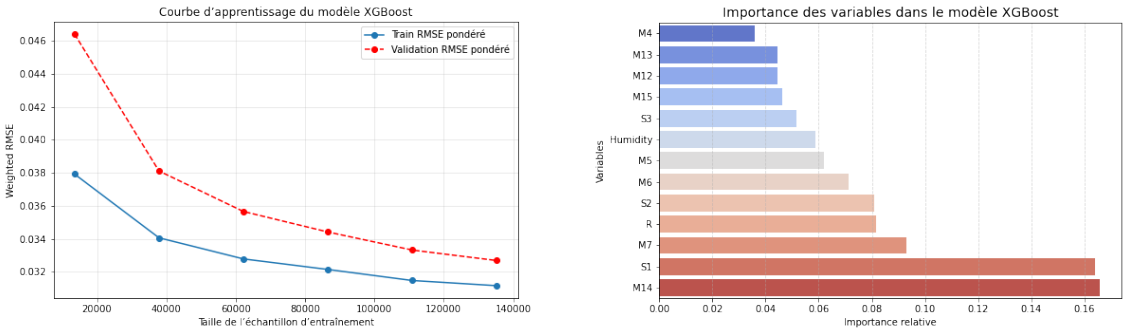
5 Modélisation et optimisation des hyperparamètres

Le modèle retenu pour cette étude est XGBoost, un algorithme d'ensemble fondé sur des arbres de décision. Il a été choisi pour sa capacité à modéliser des relations non linéaires entre les mesures des capteurs et les niveaux d'alarme, et pour sa robustesse face au bruit et aux variables corrélées. Contrairement aux approches linéaires classiques, il prend efficacement en compte les interactions entre variables et permet d'obtenir de bonnes performances sans nécessiter une transformation complexe des données. Par exemple, la relation entre la concentration d'un gaz et la réponse d'un capteur n'est pas nécessairement linéaire, et l'humidité influence également leurs mesures, XGBoost est particulièrement adapté à la modélisation de ces interactions complexes.
Pour améliorer encore ses résultats, l'optimisation des principaux hyperparamètres a été réalisée à l'aide de la bibliothèque Optuna, selon une recherche bayésienne sur 25 essais. Cette approche permet d'explorer automatiquement l'espace des paramètres afin de minimiser la métrique du challenge, le Weighted RMSE. L'optimisation a conduit à un ensemble de paramètres qui équilibrent la précision et la stabilité du modèle.
Les meilleurs hyperparamètres obtenus sont :

`max_depth`	6	`reg_alpha`	4.0024
`learning_rate`	0.0499	`reg_lambda`	6.5640
`subsample`	0.8219	`colsample_bytree`	0.8504

6 Évaluation du modèle

L'évaluation du modèle combine l'analyse de sa performance et l'interprétation des facteurs les plus importants. Ces résultats sont visualisés à travers la courbe d'apprentissage et l'analyse des importances des variables.
La courbe d'apprentissage du modèle XGBoost illustre une diminution progressive du Weighted RMSE pour les ensembles d'entraînement et de validation lorsque la taille de l'échantillon augmente. L'écart entre les deux courbes reste modéré, ce qui suggère que le modèle apprend efficacement sans surajuster les données d'entraînement. La stabilisation des erreurs sur l'ensemble de validation confirme une bonne capacité de généralisation.
L'optimisation des hyperparamètres a conduit à un score de validation optimal de 0.0322 selon la métrique Weighted RMSE. Après réentraînement sur l'ensemble des données, le modèle final atteint un score en échantillon de 0.0557. Le fait que l'erreur d'entraînement soit légèrement supérieure à celle de validation peut s'expliquer par la composition des sous-ensembles utilisés lors de la validation croisée. Ce comportement reste cohérent avec une bonne généralisation du modèle et ne traduit pas de surapprentissage.
L'analyse des importances montre que les variables M14, S1 possèdent les contributions les plus élevées au modèle, indiquant qu'elles capturent des signaux particulièrement discriminants pour la détection des gaz. Les autres capteurs, tels que M4 ou M13, présentent une influence plus limitée. Ces résultats suggèrent que le modèle XGBoost parvient à identifier correctement les mesures les plus pertinentes pour la tâche de prédiction.



(a) Courbe d'apprentissage du modèle XGBoost.

(b) Importance des variables.

Figure 3: Évaluation du modèle XGBoost

7 Bilan de la Modélisation : Succès, Obstacles et Résultats

Le modèle final, fondé sur l'algorithme XGBoost associé à une réduction de dimension par PCA, a obtenu les performances suivantes lors de l'évaluation finale du challenge :

- Score public : 0.1451
- Score privé : 0.1449

Ces résultats proches confirment la stabilité et la capacité de généralisation du modèle. Ils résultent d'un processus itératif combinant rigueur méthodologique et ajustements expérimentaux.

Succès et réalisations. L'application d'une PCA sur les cibles a permis de réduire la redondance entre les 23 variables fortement corrélées et de conserver l'essentiel de l'information. Cette approche a joué un rôle de régularisation efficace, qui améliore la robustesse du modèle face au bruit et au distribution shift entre les ensembles d'entraînement et de test. L'optimisation des hyperparamètres avec Optuna a permis d'obtenir un équilibre optimal entre complexité et performance tandis qu'une normalisation rigoureuse des données a garanti l'absence de toute fuite d'information.

Obstacles et défis rencontrés. Le principal défi provenait de la distribution shift entre les conditions d'entraînement et de test, notamment en termes d'humidité et de concentration des gaz. Les tentatives d'ingénierie de caractéristiques avancée, bien que cohérentes avec l'analyse exploratoire (corrélation entre capteurs et non-linéarité de l'humidité), n'ont pas conduit à des gains significatifs. Ces observations ont confirmé qu'une stratégie de régularisation forte et de simplicité structurelle était plus efficace qu'une modélisation trop complexe des dépendances internes aux données.