Reading Images Like Texts: Sequential Image Understanding in Vision-Language Models

Linshuo CHEN, Keyi LIU
Sorbonne Université Sciences, Paris VI

Introduction

Les modèles VLM représentent les images comme des séquences de tokens, mais parviennent néanmoins à raisonner sur les objets et l'espace.

Ce travail analyse comment les sémantiques d'objets et les relations spatiales émergent de flattened representations, inspirées des voies visuelles humaines « what » et « where ».

À partir de ces analyses, l'article propose une compression au niveau des tokens pour un décodage plus efficace ainsi qu'un redimensionnement de RoPE afin d'améliorer le raisonnement spatial.

Méthodologie : Décoder « What » et « Where »

Voie « What » — Reconnaissance d'objets

- Utilisation du Logit Lens pour décoder les représentations visuelles en text tokens.
- Les token maps visualisent la correspondance directe entre patches et concepts sémantiques.
- Les segmentation maps montrent la formation progressive des catégories d'objets.

Voie « Where » — Perception spatiale

- Analyse théorique du rôle de RoPE 2D dans l'encodage des relations spatiales relatives.
- Les relations spatiales sont représentées par des vecteurs de direction dans l'espace latent.
- Une visualisation par PCA révèle une géométrie spatiale structurée.

Découverte principale

Voie « What »

Le traitement visuel dans les VLMs suit un processus en deux étapes, de couches peu profondes à profondes.

Cette dynamique explique comment des tokens visuels discontinus forment des concepts cohérents.

Étape 1 — Reconnaissance d'attributs (couches peu profondes → intermédiaires)

Le modèle identifie des caractéristiques locales telles que la couleur ou la texture.

Les tokens décodés correspondent à des attributs visuels (ex. "fur", "white", "wood").

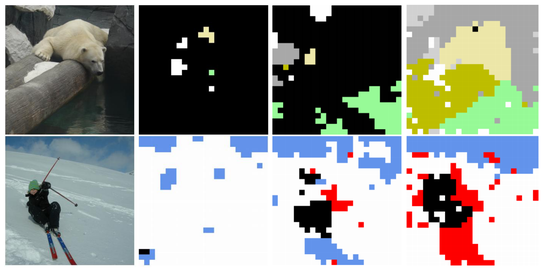
À ce stade, les objets ne sont pas encore clairement distingués.

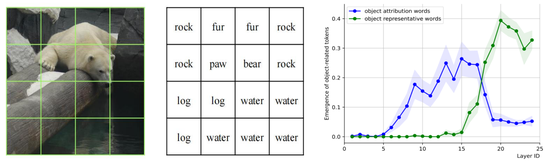
Étape 2 — Désambiguïsation sémantique (couches intermédiaires → profondes)

Le modèle intègre les attributs locaux en concepts globaux d'objets.

Les tokens décodés deviennent des noms d'objets (ex. "bear", "rock").

Les frontières entre objets deviennent spatialement cohérentes.





Voie « Where »

Les relations spatiales sont encodées sous forme de vecteurs géométriques.

Gauche / droite et devant / derrière occupent des directions distinctes dans l'espace latent.

Cette géométrie est induite par RoPE.

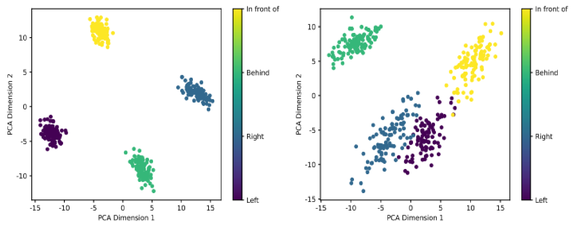


Figure - Résultats de la PCA des vecteurs de direction pour les relations gauche/droite et devant/derrière, avec et sans embedding positionnel.

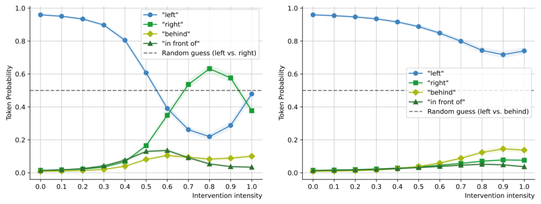


Figure - L'intervention sur les embeddings visuels

Application

Application1 - Token Compression

- Compression basée sur RLE
- Les tokens visuels répétés sont regroupés
- Un décodeur visuel aide à identifier les tokens à conserver.

Application 2 — RoPE Scaling

- RoPE standard peut affaiblir l'information de position.
- RoPE Scaling renforce les signaux spatiaux importants selon :

$$g(i) = 1 + \alpha\left(\frac{2i}{d}\right)^{p}$$

- Le raisonnement spatial est amélioré sur plusieurs benchmarks.

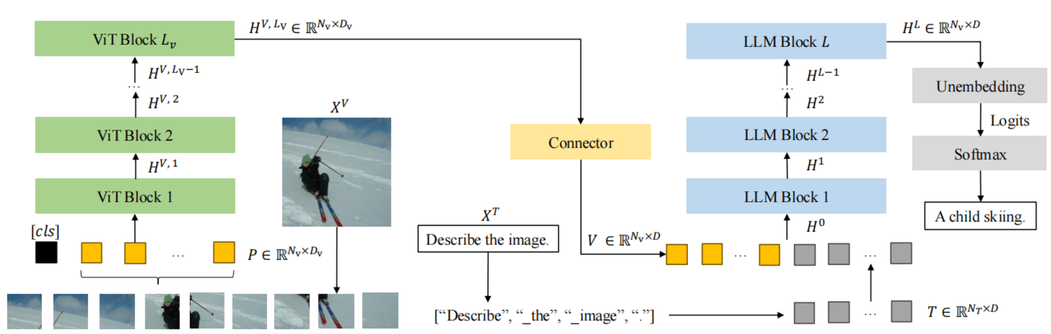


Figure - Architecture typique d'un modèle VLM. Il se compose d'un visual encoder, d'un connecter et d'un decoder-only modèle de langage.

Résultats

Methods & Datasets	VQA$^{v2.0}$	GQA	ScienceQA	TextVQA	MMBench^{EN}	POPE	Reduction rate (%)
Original Decoding							
LLaVA-1.5-7B	48.93	60.50	48.46	45.01	53.73	85.96	/
Qwen2.5-VL-7B	79.04	61.20	80.55	78.21	84.68	89.23	/
method1: Runlength compression							
LLaVA-1.5-7B	49.24	61.32	47.37	43.16	51.40	86.00	27.83
Qwen2.5-VL-7B	77.91	60.80	80.71	76.33	84.27	87.46	16.19
method2: Runlength compression + Remove punctuation (Look at Top1 token)							
LLaVA-1.5-7B	48.59	60.14	46.59	35.04	47.33	85.66	58.35
Qwen2.5-VL-7B	77.24	58.69	79.70	71.80	83.39	85.70	45.00
method3: Runlength compression + Remove punctuation (Look at Top2 tokens)							
LLaVA-1.5-7B	49.12	61.06	47.18	38.53	50.45	85.90	48.55
Qwen2.5-VL-7B	77.38	60.03	80.48	74.78	83.58	86.83	32.09

La compression par RLE réduit la longueur des séquences jusqu'à 58 %, tout en préservant largement les performances sur les benchmarks VQA.

Methods & Datasets	What's Up A	What's Up B	VSR	COCO-spatial 1	COCO-spatial 2	GQA-spatial 1	GQA-spatial 2
Qwen2-VL-2B	74.61	53.16	73.30	49.84	58.18	76.61	76.98
Qwen2-VL-2B + RoPE scaling	77.27	58.25	73.75	50.24	58.24	78.22	78.03
Qwen2-VL-2B + SFT	78.54	61.52	73.98	58.08	**66.59**	81.29	83.05
Qwen2-VL-2B + SFT + RoPE scaling	**79.42**	**63.48**	**74.17**	**59.03**	**66.59**	**82.24**	**83.33**
Qwen2-VL-7B	98.06	87.84	77.77	88.79	70.45	92.84	84.54
Qwen2-VL-7B + RoPE scaling	98.86	88.97	78.09	89.27	72.05	94.31	85.65
Qwen2-VL-7B + SFT	98.98	90.00	80.96	89.05	74.55	96.72	**95.42**
Qwen2-VL-7B + SFT + RoPE scaling	**99.03**	**90.44**	**81.14**	**89.67**	**75.45**	**96.98**	94.5

Le RoPE scaling renforce le raisonnement spatial sur l'ensemble des benchmarks évalués.

Conclusion

- Cette étude éclaire la manière dont les VLMs comprennent les objets et les relations spatiales.
- L'analyse du what et du where révèle des structures internes interprétables.
- Ces observations conduisent à des améliorations pratiques en efficacité et en raisonnement spatial.

Références

[1] Hila Chefer, Shir Gur, and Lior Wolf.
Transformer interpretability beyond attention visualization. 2021.
[2] Clement Neo, Luke Ong, Philip Torr, Mor Geva, David Krueger, and Fazl Barez.
Towards interpreting visual information processing in vision-language models. 2024.
[3] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin.
Attention Is All You Need. 2017.